udp Escuela de Informática y Telecomunicaciones
FACULTAD DE INGENIERÍA Y CIENCIAS

Escuela de Informática y Telecomunicaciones
Inteligencia Artificial
Profesores: Johan Fuentes, Víctor Reyes y Felipe Lazo
Tarea 2

Rúbrica de Evaluación: Tarea 2

Instrucciones a tener en consideración:

1. La tarea se debe realizar en **Jupyter Notebook**.
2. La tarea se puede desarrollar en grupos de **2 o 3 estudiantes**. Basta con que solo 1 estudiante entregue la tarea.
3. El nombre del archivo debe tener el siguiente formato:
   `Nombre1_Apellido1_Nombre2_Apellido2_Tarea1.ipynb` o
   `Nombre1_Apellido1_Nombre2_Apellido2_Nombre3_Apellido3_Tarea1.ipynb`
4. Al inicio del notebook deben estar los nombres de los estudiantes que realizaron la tarea.
5. **Fecha de entrega: Viernes 6 de Noviembre, a las 23:59.** No se considerará extensión de plazo.
6. En caso de utilizar herramientas generativas, se deberá declarar su propósito. Está **estrictamente prohibido su uso para la elaboración de análisis de resultados y diseño de soluciones.**
7. Algunos trabajos podrán ser seleccionados para interrogación oral. En tal caso, la nota podrá ser ajustada en función del desempeño.

Descuentos y Penalizaciones

Las siguientes sanciones se aplicarán de manera automática sobre la nota final de la tarea ante el incumplimiento de las directrices formales de entrega:

Infracción	Sanción / Descuento
Uso o entrega mediante Google Colab	Descuento de 20 puntos.
No inclusión de la Declaración de IA	Nota Mínima (1.0) de acuerdo con las condiciones obligatorias de entrega del enunciado.
Uso de IA en análisis o diseño de soluciones	Nota Mínima (1.0) de acuerdo con las condiciones obligatorias de entrega del enunciado.
Código que no se ejecuta	Nota Mínima (1.0) de acuerdo con las condiciones obligatorias de entrega del enunciado.
Análisis en celdas de código o en archivos separados	Descuento de 20 puntos. El análisis técnico debe redactarse obligatoriamente utilizando celdas de texto (Markdown).
Faltas de Ortografía y Redacción reiteradas	Descuento de 20 puntos.
No participación en el trabajo grupal	Nota Mínima (1.0).

Sección	Nº ID	ÍTEM	Logrado	Medio	Bajo	No
Aprendizaje Supervisado (30 pts total)	**1.1**	Se selecciona un dataset con al menos 20.000 filas y 12 columnas utilizables, el cual se divide en conjuntos de 70 % entrenamiento, 15 % validación y 15 % prueba.	2	1	1	0
	1.2	Se selecciona una variable continua Y_1 y una variable discreta binaria Y_2 como variable objetivo, ambas justificadas y realizadas exclusivamente con los datos de entrenamiento.	3	2	1	0
	1.3	Se predice Y_1 utilizando regresión lineal y se predice Y_2 utilizando regresión logística, en ambos casos utilizando inicialmente las mismas 10 variables predictoras $X_1 ... X_{10}$.	4	[2-3]	1	0
	1.4	Se entrenan tres versiones del modelo para cada tarea: (1) utilizando las 10 variables predictoras, (2) utilizando las 5 variables más relevantes y (3) utilizando solo las 3 más relevantes.	4	[2-3]	1	0
	1.5	Utilizando métricas apropiadas para cada tarea, se compara el desempeño de las tres versiones en los conjuntos de entrenamiento y validación. Luego, se evalúan en el conjunto de prueba las dos versiones con mejor desempeño en el conjunto de validación.	8	[4-7]	[1-3]	0
	1.6	Se analiza cómo influye la cantidad de variables predictoras en el desempeño y la capacidad de generalización de los modelos, discutiendo posibles situaciones de *overfitting* o *underfitting*.	9	[5-8]	[1-4]	0
Aprendizaje Supervisado vs. Semisupervisado (30 pts total)	**2.1**	Se selecciona un dataset de clasificación distinto al de la pregunta 1, con al menos 15.000 filas, 7 características y una etiqueta con más de dos clases. Se divide en 80 % entrenamiento y 20 % testing, y se construyen los dos escenarios en que solo el 10 % y el 30 % del conjunto de entrenamiento poseen etiquetas conocidas.	3	2	1	0
	2.2	Se entrenan Regresión Logística y SVM utilizando únicamente las muestras etiquetadas, en ambos escenarios (10 % y 30 %), estableciendo la línea base supervisada.	4	[2-3]	1	0
	2.3	Se implementan K-Means y DBSCAN con al menos dos configuraciones por técnica, justificando la elección de sus parámetros.	4	[2-3]	1	0
	2.4	Se diseña una estrategia de asignación de pseudoetiquetas a los datos no etiquetados, buscando alcanzar el 60 % del conjunto de entrenamiento entre etiquetas reales y estimadas.	2	1	1	0
	2.5	Se justifican los criterios de asignación y las limitaciones que impidan alcanzar dicho porcentaje.	3	2	1	0

Sección	Nº ID	ÍTEM	Logrado	Medio	Bajo	No
Aprendizaje Supervisado vs. Semisupervisado (continuación)	**2.6**	Se reentrenan ambos clasificadores incorporando las pseudoetiquetas. Para cada combinación se investigan y justifican al menos tres configuraciones de hiperparámetros, seleccionando la mejor mediante validación cruzada, sin utilizar las etiquetas desconocidas ni el conjunto de testing. Se registran todas las configuraciones evaluadas, indicando las funciones de pérdida y métricas utilizadas.	5	[3-4]	[1-2]	0
	2.7	Se comparan los seis mejores enfoques (dos supervisados y cuatro semisupervisados) en ambos escenarios, utilizando al menos tres semillas aleatorias y métricas apropiadas para clasificación multiclase.	4	[2-3]	1	0
	2.8	Se analiza cómo influyen los hiperparámetros, la cantidad de etiquetas reales y la calidad de las pseudoetiquetas en el desempeño de los modelos, justificando las conclusiones con los resultados obtenidos.	5	[3-4]	[1-2]	0
Clustering y detección de anomalías meteorológicas (20 pts total) — **Solo para grupos de tres integrantes**	**3.1**	Selecciona un dataset meteorológico con al menos 15.000 observaciones temporales y 8 características, descartando las variables objetivo o etiquetas y trabajando en un escenario no supervisado, sin registros ni confirmaciones visuales que permitan establecer el ground truth.	2	1	1	0
	3.2	Aplica una técnica de reducción de dimensionalidad espacial, justificando estadísticamente la cantidad de información retenida y su pertinencia para representar las variables atmosféricas.	4	[2-3]	1	0
	3.3	Implementa dos enfoques de clustering: uno basado en la asignación al centroide más cercano y otro basado en densidad, capaz de identificar observaciones dispersas como posibles anomalías.	4	[2-3]	1	0
	3.4	Define, aplica y justifica métricas de validación interna apropiadas para evaluar la calidad geométrica de las agrupaciones obtenidas por ambos algoritmos.	3	2	1	0
	3.5	Compara los resultados de ambos enfoques, analizando cómo la normalización y la métrica de distancia seleccionadas influyen en la forma final de los clústeres y en la sensibilidad a la detección de anomalías, considerando las diferencias de escala y naturaleza de las variables atmosféricas.	4	[2-3]	1	0
	3.6	Analiza la distribución cronológica de las anomalías detectadas, evaluando si ocurren de forma contigua y aportando evidencia matemática para discutir las etapas de formación, clímax y disipación de la tormenta.	3	2	1	0

Cualquier consulta escribir a los correos:

- **vicente.leiva2@mail.udp.cl** (sección 01)
- **felipe.maturana1@mail.udp.cl** (sección 02)
- **isidora.gonzalez4@mail.udp.cl** (sección 03)