Universidad Diego Portales
Facultad de Ingeniería y Ciencias

Tarea Nº 2
Inteligencia Artificial **VR-JF-FL**

Fecha: Jueves 15 de Octubre de 2026

1. **(30 puntos)** En esta pregunta deberá aplicar dos algoritmos de aprendizaje supervisado sobre un dataset de su elección, el cual debe tener al menos 20.000 filas y 12 columnas utilizables. Deberá seleccionar una variable continua Y_1 y una variable discreta binaria Y_2 como variables objetivo. Para predecir Y_1, deberá utilizar regresión lineal; para predecir Y_2, regresión logística. En ambos casos, deberá utilizar inicialmente las mismas 10 variables predictoras $X_1,...,X_{10}$. El dataset deberá dividirse en 70% entrenamiento, 15% validación y 15% prueba. Para cada tarea, deberá entrenar tres versiones del modelo: una utilizando las 10 variables predictoras, otra utilizando las 5 variables más relevantes y una tercera utilizando solo las 3 más relevantes. La selección de variables deberá justificarse y realizarse exclusivamente con los datos de entrenamiento. Luego, deberá comparar el desempeño de las tres versiones en los conjuntos de entrenamiento y validación, utilizando métricas apropiadas para cada tarea. Para cada tarea, deberá evaluar en el conjunto de prueba únicamente las dos versiones con mejor desempeño en validación. Finalmente, deberá analizar cómo influye la cantidad de variables predictoras en el desempeño y la capacidad de generalización de los modelos, discutiendo posibles situaciones de *overfitting* o *underfitting*.

2. **(30 puntos)** Utilizando un dataset de clasificación (distinto al anterior) con al menos 15.000 filas, 7 características y una etiqueta Y discreta con más de dos clases, deberá comparar aprendizaje supervisado y semisupervisado. Divida los datos en un 80% de entrenamiento y un 20% de testing, considerando dos escenarios donde únicamente el 10% y el 30% del conjunto de entrenamiento poseen etiquetas conocidas. Para cada escenario, entrene Regresión Logística y SVM utilizando solo las muestras etiquetadas. Posteriormente, implemente K-Means y DBSCAN con al menos dos configuraciones por técnica y diseñe una estrategia para asignar pseudoetiquetas a los datos restantes, buscando alcanzar un 60% del conjunto de entrenamiento entre etiquetas reales y estimadas. Justifique los criterios de asignación y cualquier limitación que impida alcanzar dicho porcentaje. Entrene nuevamente ambos clasificadores incorporando las pseudoetiquetas obtenidas. Para cada combinación, investigue y justifique al menos tres configuraciones de hiperparámetros, seleccionando la mejor mediante validación cruzada, sin utilizar las etiquetas desconocidas ni el conjunto de testing. Registre y analice todas las configuraciones evaluadas, indicando las funciones de pérdida y métricas utilizadas. Finalmente, compare los seis mejores enfoques (dos supervisados y cuatro semisupervisados) en ambos escenarios, utilizando al menos tres semillas aleatorias. Analice cómo influyen los hiperparámetros, la cantidad de etiquetas reales y la calidad de las pseudoetiquetas en el desempeño, justificando sus conclusiones.

3. (**20 puntos, solo para grupos de a tres**) En el contexto de la inusual tormenta eléctrica registrada en Santiago, deberá abordar la identificación de estados meteorológicos y la detección de eventos climáticos extremos asumiendo una ausencia total de registros o confirmaciones visuales (ground truth). Para este ejercicio, el desafío consiste en descubrir la firma matemática de la tormenta basándose únicamente en la estructura de los datos. Seleccione un dataset meteorológico con al menos 15.000 observaciones temporales y 8 características de la zona (como presión, humedad, temperatura, etc.). Asegúrese de descartar cualquier variable objetivo o etiqueta, trabajando en un escenario puramente no supervisado.

   Primero, dado que las variables atmosféricas suelen estar altamente correlacionadas, investigue y aplique una técnica de reducción de dimensionalidad espacial, justificando estadísticamente la cantidad de información retenida. Posteriormente, implemente dos enfoques distintos de agrupamiento (clustering) para descubrir los diferentes "estados" latentes del clima:

   1. Una estrategia que busque particionar el espacio asignando las observaciones al centroide más cercano.
   2. Una estrategia que agrupe los datos basándose en áreas de alta densidad, aislando las zonas dispersas.

   Defina, aplique y justifique el uso de métricas de validación interna para evaluar la calidad geométrica de estas agrupaciones.

   Finalmente, elabore una discusión técnica comparativa analizando:

   a) Considerando la distinta naturaleza matemática y magnitud de las variables atmosféricas (ej. presión en hPa frente a ráfagas de viento en km/h), discuta cómo el método utilizado para normalizar los datos (preprocesamiento) y la métrica de distancia seleccionados determinaron la forma final de los clústeres y la sensibilidad en la detección de anomalías.

   b) Aunque los algoritmos de agrupamiento evaluaron cada registro de forma independiente y sin noción del tiempo, analice si las observaciones identificadas como anomalías ocurrieron de forma contigua cronológicamente, evidenciando matemáticamente el ciclo de vida de la tormenta (formación, clímax y disipación).

Importante

En caso de utilizar herramientas generativas, se deberá declarar específicamente el propósito para el que fueron empleadas. Está **estrictamente prohibido** su uso para el diseño de soluciones o la elaboración de análisis de resultados.

Asimismo, algunos trabajos, seleccionados de forma aleatoria, podrán ser objeto de una interrogación oral. En tales casos, la calificación podrá ser modificada en función del

desempeño en dicha instancia. Si el trabajo no es seleccionado, la nota original se mantendrá.

Condiciones de entrega

Se indican las siguientes condiciones para la entrega de la tarea:

- La tarea se desarrolla **parejas o grupos de a tres** a través de Jupyter Notebook. Está estrictamente prohibido trabajar de manera individual.
- Es requisito indispensable que los códigos se ejecuten **sin cambios**. De no cumplirse esta condición, la tarea será evaluada con nota mínima de inmediato.
- La tarea se entregará vía el Canvas del curso. La fecha y hora límite para la entrega es el día Viernes 6 de Noviembre a las 23:59. Cualquier entrega atrasada no se considerará y será calificada con la nota mínima de inmediato. **No habrá extensión de plazo.**